



**INSTITUTO
FEDERAL**
Ceará

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DO CEARÁ -
CAMPUS CANINDÉ

ANÁLISE E DESENVOLVIMENTO DE SISTEMAS
INTELIGÊNCIA ARTIFICIAL

RELATÓRIO IV

ISMAEL FERNANDES BRITO

CANINDÉ - CE
2022

1 Introdução

Inteligência Computacional Aplicada é uma área de conhecimento da computação que vem ganhando bastante destaque nos últimos anos em virtude de ser composto de diversas ferramentas que permitem resolver problemas que não são possíveis de serem solucionados pela programação tradicional.

Classificadores neurais são ferramentas que realizam reconhecimento de padrões por meio da classificação baseadas nos neurônios artificiais do tipo perceptron. São exemplos de algoritmos de classificação neural o classificador perceptron simples (PS), o classificador perceptron simples com multiclases e o classificador perceptron multicamadas (MLP).

Todo o trabalho foi implementado utilizando as notas de aula e os scripts em linguagem de programação R utilizando os conjuntos de dados do iris, parkinson e dermatology nos testes que este trabalho aborda.

2 Dados Utilizados

O conjunto de dados do Iris tem 150 observações com quatro atributos - comprimento da sépala, largura da sépala, comprimento da pétala e largura da pétala e o rótulo contendo três espécies - iris setosa, iris virginica e iris versicolor. Cada uma das espécies tem 50 observações. O conjunto de dados do Parkinson tem 195 observações com 24 atributos e o rótulo com classificação binária, 0 para saudável e 1 para doença de parkinson. O conjunto de dados do Dermatology tem 365 observações com 34 atributos e o rótulo contém 6 classes, a classe 1 - psoríase, classe 2 - dermatite seborréica, classe 3 - líquen plano, classe 4 - pitiríase rósea, classe 5 - dermatite crônica e classe 6 - pitiríase rubra pilar.




Figura 1: Conjunto de dados Iris




Figura 2: Conjunto de dados Parkinson




Figura 3: Conjunto de dados Dermatology

3 Metodologia

Aplicando o classificador perceptron multicamadas (MLP) aos conjuntos de dados do iris, parkinson e dermatology, utilizando o R para a implementação computacional com o seguinte procedimento abaixo:

- Carregamento do conjunto de dados;
- Divisão do conjunto de dados em treinamento (80%) e teste (20%);
- Execução das 10 rodadas entre treinamento e teste;
- Cálculo da taxas de acerto, máxima, mínima e média;
- Matriz de confusão do melhor resultado.

4 Parâmetros Gerais

O MLP foi implementado seguindo os critérios para se obter a melhor ajuste possível. Neste caso a dimensão da camada de entrada denotamos por (p) e a camada de saída denotamos por (m), optamos por ter uma camada oculta denotada por (q). Foi feito testes variando a quantidades de neurônios da camada oculta utilizando a Regra de Kolmogorov ou a Regra da média, com no máximo de 1000 épocas, onde obtivemos o melhor ajuste para os conjuntos de dados também chamada de camada escondida como mostrado na Tabela 1.

Quando se implementa o MLP, devemos ter em mente que vamos ter vários parâmetros para ajustar que impactam no desempenho do modelo e também seu alto custo computacional, tudo isso deve ser levado em consideração quando se utiliza esse modelo. Por mais que seja um modelo robusto, não significa dizer que terá o melhor resultado.

5 Resultados

5.1 Conjunto de dados Iris

Foi feito uma alteração para testar o classificador utilizando diferentes combinações dos atributos de entrada e feito o comparativo entre as combinações de características e seus resultados de taxa de acerto conforme a Tabela 01.

Tabela 01 - Comparação de número de atributos e taxa de acerto do conjunto de dados Iris

Nº de Atributos	taxa de acerto
4	95%
3	84%
2	79%
1	—

Tabela 02 - Métricas de Avaliação do conjunto de dados Iris

	Perceptron Multicamadas (MLP)
Mínimo	90%
Médio	95%
Máximo	100%
Desvio padrão	3,93%

5.2 Matriz de confusão do conjunto de dados Iris

		Resposta da rede		
		setosa	versicolor	virginica
Resposta desejada	setosa	11	0	0
	versicolor	0	8	0
	virginica	0	0	11

5.3 EQM do conjunto de dados Iris




Figura 4: Erro Quadrático Médio do conjunto de dados Iris

Foram feitos vários teste para verificar qual dos parâmetros utilizados foi o melhor nesse conjunto de dados e obtivemos o seguinte resultado.

- Número de neurônios da camada de entrada (p) \Rightarrow 4;
- Número de neurônios da camada oculta (q) \Rightarrow 9;
- Número de neurônios da camada de saída \Rightarrow 3;
- Passo de aprendizagem \Rightarrow 0.01;
- Número de épocas \Rightarrow 100.

Como esse conjunto de dados é balanceado, então não precisamos de muitos neurônios para realizar a tarefa de classificação e também por ter poucas amostras o processo de treinamento e teste é muito rápido, ou seja, exige menos esforço computacional para esta tarefa.

5.4 Conjunto de dados Parkinson

Tabela 03 - Métricas de Avaliação do conjunto de dados Parkinson

	Perceptron Multicamadas (MLP)
Mínimo	35,90%
Médio	82,56%
Máximo	97,44%
Desvio padrão	17,51%

5.5 Matriz de confusão do conjunto de dados Parkinson

		Resposta da rede	
		Classe 0	Classe 1
Resposta desejada	Classe 0	2	2
	Classe 1	4	31

5.6 Comparação entre vários modelos no conjunto de dados Parkinson

Tabela 04 - Comparação entre PS, MLP, KNN e DMC usando a taxa de acerto do conjunto de dados Parkinson

Modelos	Taxa de acerto
PS	89,74%
KNN	92,31%
DMC	79,49%
MLP	82,56%

Quando comparamos os modelos aplicado neste conjunto de dados, observamos que não precisamos usar modelos muito sofisticado, pois quanto mais sofisticado for o modelo mais parâmetros precisa ser ajustado para obter o melhor resultado, ou seja, mais difícil se torna essa tarefa já que precisamos testar muitas combinações de valores sem contar também o gasto de tempo na execução do mesmo por isso é sempre melhor ficar o modelo que tiver o melhor número de parâmetros, ou seja, um modelo mais simples.

5.7 EQM do conjunto de dados Parkinson




Figura 5: Erro Quadrático Médio do conjunto de dados Parkinson

Foram feitos vários teste para verificar qual dos parâmetros utilizados foi o melhor nesse conjunto de dados e obtivemos o seguinte resultado.

- Número de neurônios da camada de entrada (p) $\Rightarrow 22$;
- Número de neurônios da camada oculta (q) $\Rightarrow 12$;
- Número de neurônios da camada de saída $\Rightarrow 2$;
- Passo de aprendizagem $\Rightarrow 0.05$;
- Número de épocas $\Rightarrow 1000$.

Como esse conjunto de dados é desbalanceado, então é muito provável que ele tende a acertar mais a classe 1, ou seja, a classe de pessoas com DP, sem contar que exige um tempo considerável para executa-lo e quanto mais aumentarmos os valores dos parâmetros não significa que obteremos um resultado melhor.

5.8 Conjunto de dados Dermatology

- Número de neurônios da camada de entrada (p) $\Rightarrow 34$;
- Número de neurônios da camada oculta (q) $\Rightarrow 69$;
- Número de neurônios da camada de saída $\Rightarrow 6$;
- Passo de aprendizagem $\Rightarrow 0.05$;
- Número de épocas $\Rightarrow 1000$.

5.9 Matriz de confusão do conjunto de dados Dermatology

		Resposta da rede					
		Classe 1	Classe 2	Classe 3	Classe 4	Classe 5	Classe 6
Resposta desejada	Classe 1	27	0	0	0	0	0
	Classe 2	0	10	0	0	1	0
	Classe 3	0	0	14	0	0	0
	Classe 4	0	1	0	12	0	0
	Classe 5	0	0	0	0	4	0
	Classe 6	0	0	0	0	0	4

5.10 EQM do conjunto de dados Dermatology




Figura 6: Erro Quadrático Médio do conjunto de dados Dermatology

5.11 Comparação entre vários modelos no conjunto de dados Dermatology

Tabela 04 - Comparação entre PS, MLP, KNN e DMC usando a taxa de acerto do conjunto de dados Dermatology

Modelos	Taxa de acerto
PS	85,13%
KNN	97,26%
DMC	53,43%
MLP	97,26%

Como esse conjunto de dados é desbalanceado, então é muito provável que ele tende a acertar mais a classe 1, sem contar que exige um tempo considerável para executá-lo e quanto mais aumentarmos os valores dos parâmetros não significa que obteremos um resultado melhor. E neste caso o classificador não-neural KNN obteve o mesmo resultado do MLP porém com a vantagem de ter apenas um parâmetro que é a quantidade de K um hiperparâmetro em que o algoritmo só roda se tiver esse valor.

5.12 Porta Lógica XOR




Figura 7: Gráfico de separação dos pontos na porta lógica XOR

5.13 Porta Lógica XNOR




Figura 8: Gráfico de separação dos pontos na porta lógica XNOR

6 Conclusão

Este estudo teve como meta a aplicação do MLP com o objetivo de obter o melhor resultado para os conjuntos de dados usando a melhor escolha de parâmetros. O MLP, é mais indicado para problemas de classificação de padrões, porém dependendo dos parâmetros utilizados sua implementação se torna difícil e também exige um maior esforço a depender do número de neurônios e épocas.